

SAE 6

**Outil décisionnel,
Modélisation statistique
et Intelligence Artificielle**

De la donnée brute
au tableau de bord

Analyse des valeurs foncières

11 JUIN 2026

BUT 3 Science des Données

Créé par : Maxime DEBURGGRAEVE

Cyprien ROBART



BUT
Science des
données



**Université
de Lille**

Sommaire

INTRODUCTION	3
Gestion de projet.....	4
Analyse du jeu de données et rétroconception de la base de données source	5
D'où viennent les données ?	5
Qu'y a-t-il dans le fichier ?	6
Les informations disponibles et les cases vides	6
Les zones oubliées et les délais	6
Présentation et Analyse du MCD retenu	7
Règles de passage au MLD et normalisation	8
Respect des Formes Normales (1FN, 2FN, 3FN)	8
Traduction des associations (Clés étrangères).....	8
Conception du modèle décisionnel et implémentation dans un SGBD	9
Identification des faits et dimensions	9
Conception du schéma en étoile	10
Alimentation de l'entrepôt de données avec un ETL	11
Choix technologiques et stratégie d'architecture	11
Conception et étapes du flux ETL	11
Étape 1 : Extraction et sécurisation du typage	11
Étape 2 : Nettoyage et normalisation des données (Data Cleaning).....	11
Étape 3 : Chargement dans la base relationnelle intermédiaire (OLTP).....	12
Étape 4 : Transformation multidimensionnelle (OLAP)	12
Visualisation des données et création de tableaux de bord	13
CONCLUSION	18

INTRODUCTION

Dans un contexte de forte numérisation de l'action publique et d'essor de l'Open Data, l'accès aux données économiques est devenu un enjeu stratégique pour l'analyse des territoires. L'un des exemples les plus significatifs en France est la mise à disposition gratuite du jeu de données DVF (Demandes de Valeurs Foncières). Publié par l'organisme d'État Etalab et alimenté à la source par l'administration fiscale et les études notariales, ce fichier recense l'intégralité des mutations immobilières à titre onéreux réalisées sur le territoire national.

Cependant, la richesse de ce jeu de données s'accompagne d'une complexité technique majeure. Le fichier brut DVF se présente sous la forme d'un fichier plat volumineux (format CSV), caractérisé par une structure dénormalisée, des redondances massives d'informations administratives, ainsi que la présence de nombreuses valeurs manquantes. De plus, sa granularité est particulière : une seule et même transaction immobilière (une mutation) peut s'étendre sur plusieurs lignes pour dissocier les parcelles, les locaux et les lots de copropriété associés. En l'état, ce format de stockage "opérationnel" est totalement inadapté à une exploration analytique rapide ou à des fins de Business Intelligence.

L'objet de ce projet est donc de concevoir une architecture de données complète, capable de collecter, nettoyer, stocker et restituer intelligemment ces données foncières. Le défi consiste à faire migrer cette source d'informations brute à travers différents niveaux d'abstractions informatiques : d'abord vers un modèle relationnel hautement structuré garantissant l'intégrité des données, puis vers un modèle multidimensionnel en étoile optimisé pour le requêtage de masse, et enfin vers un environnement de datavisualisation interactif.

Pour rendre compte de cette démarche d'ingénierie des données, notre rapport s'articulera autour de quatre parties majeures :

1. Analyse du jeu de données et rétroconception de la base de données source
2. Conception du modèle décisionnel et implémentation dans un SGBD
3. Alimentation de l'entrepôt de données avec un pipeline ETL
4. Visualisation des données et création de tableaux de bord sous Power BI

Gestion de projet

La gestion de ce projet a été assurée via un repository GitHub nommé « planning SAE ». Ce dernier contient un tableau de bord projet qui retrace l'ensemble des étapes, depuis l'analyse du jeu de données jusqu'à la livraison du dashboard Power BI.

Il permet de visualiser la planification des tâches, leur répartition, les délais et l'état d'avancement (To Do / In Progress / Done).

1	☑ Prise de connaissance du sujet #5	▼	Done	▼		Mar 6, 2026	Mar 20, 2026
2	▼ ☑ Analyse du jeu de données et rétroconception de la base de données source #6	▼	Done	▼	4 / 4 100%	Mar 20, 2026	Apr 3, 2026
	☑ Analyse du fichier source : étude des colonnes, types, valeurs manquantes. #7	▼	Done	▼		Mar 20, 2026	Mar 26, 2026
	☑ Recherche sur la provenance des données (notaires, DGFiP) et les logiciels métiers utilisés #8	▼	Done	▼		Mar 26, 2026	Mar 26, 2026
	☑ Rétroconception du modèle conceptuel des données : élaboration du MCD (entités, associ... #9	▼	Done	▼		Mar 27, 2026	Apr 3, 2026
	☑ Conversion en modèle logique (MLD) avec normalisation #10	▼	Done	▼		Apr 3, 2026	Apr 3, 2026
3	▼ ☑ Conception du modèle décisionnel et implémentation dans un SGBD #11	▼	Done	▼	4 / 4 100%	Apr 6, 2026	May 7, 2026
	☑ Identifier les faits et dimensions pour le modèle en étoile. #12	▼	Done	▼		Apr 9, 2026	Apr 9, 2026
	☑ Conception du schéma étoile #13	▼	Done	▼		Apr 9, 2026	Apr 10, 2026
	☑ Implémentation SQL des tables décisionnelles. #14	▼	Done	▼		May 6, 2026	May 7, 2026
	☑ Chargement d'un jeu de données test #15	▼	Done	▼		May 7, 2026	May 7, 2026
4	▼ ☑ Alimentation de l'entrepôt de données avec un ETL #16	▼	Done	▼	5 / 5 100%	May 7, 2026	May 29, 2026
	☑ Choisir un ETL #17	▼	Done	▼		May 7, 2026	May 7, 2026
	☑ Concevoir le flux d'extraction, transformation et chargement #18	▼	Done	▼		May 21, 2026	May 21, 2026
	☑ Nettoyage des données (formats, doublons, géocodage si nécessaire) #19	▼	Done	▼		May 22, 2026	May 22, 2026
	☑ Chargement dans la base décisionnelle #20	▼	Done	▼		May 28, 2026	May 28, 2026
	☑ Automatisation de la récupération des données #21	▼	Done	▼		May 29, 2026	May 29, 2026
5	▼ ☑ Visualisation des données et création de tableaux de bord #22	▼	Done	▼	4 / 4 100%	May 29, 2026	Jun 12, 2026
	☑ Définir les objectifs métier des tableaux de bord (analyse temporelle, géographique, type... #23	▼	Done	▼		Jun 4, 2026	Jun 4, 2026
	☑ Choisir un outil de data visualisation #24	▼	Done	▼		Jun 4, 2026	Jun 4, 2026
	☑ Créer les visualisations interactives nécessaires : graphiques, cartes, filtres dynamiques, in... #25	▼	Done	▼		Jun 4, 2026	Jun 5, 2026
	☑ S'assurer de la qualité, pertinence et ergonomie du tableau de bord #26	▼	Done	▼		Jun 10, 2026	Jun 11, 2026

Cette organisation nous a permis de suivre efficacement l'avancement et de respecter les délais du projet.

Analyse du jeu de données et rétroconception de la base de données source

D'où viennent les données ?

Le fichier DVF (Demandes de valeurs foncières) est le résultat d'un parcours bien précis qui commence dès qu'une vente immobilière a lieu en France :

- **Les notaires (La collecte des informations)** : À l'origine de chaque vente, le notaire rédige l'acte officiel. En plus de son rôle juridique, il réunit toutes les caractéristiques de la transaction : le prix exact payé par l'acheteur, la description du bien (surface, nombre de pièces) et les références de la parcelle sur le plan cadastral. Pour enregistrer toutes ces données, les études notariales utilisent des logiciels professionnels spécialisés. En France, le marché est partagé par de grands éditeurs : Génapi (avec son logiciel iNot), Fiducial Informatique (Notexpert), ou encore les solutions du groupe Septeo.
- **La DGFIP (La centralisation aux Impôts)** : Une fois la vente signée, le notaire a l'obligation légale de transmettre ces informations à l'État. Cette transmission se fait de manière totalement informatique et sécurisée via un système appelé Télé@ctes. C'est la Direction Générale des Finances Publiques (DGFIP), c'est-à-dire l'administration des impôts, qui reçoit et centralise toutes ces ventes. Pour elle, cette base de données sert d'abord à calculer les taxes et à suivre l'évolution réelle des prix du marché immobilier.
- **Etalab (Le nettoyage et la publication en Open Data)** : Le fichier brut possédé par les impôts est très difficile à utiliser en l'état. C'est donc Etalab, un organisme de l'État chargé de l'ouverture des données publiques, qui prend le relais. Etalab récupère le fichier pour le réorganiser, corriger les erreurs de format et rendre les titres des colonnes plus lisibles. Surtout, ils croisent ce fichier avec les cartes du cadastre pour ajouter les coordonnées GPS (latitude et longitude) de chaque propriété. C'est ce fichier final, propre et enrichi, qui est publié gratuitement sur internet pour le grand public.

Qu'y a-t-il dans le fichier ?

Le fichier se présente sous la forme d'un grand tableau. Sa particularité est qu'une seule et même vente peut occuper plusieurs lignes. Par exemple, si vous achetez une maison avec un garage séparé et un bout de jardin, le fichier créera trois lignes distinctes, reliées par un même numéro unique appelé `id_mutation`.

Les informations disponibles et les cases vides

On trouve dans ce fichier plusieurs grands types d'informations, avec parfois quelques pièges ou des cases laissées vides :


- Les détails de la vente : Le numéro de la transaction (`id_mutation`), la date de la vente et le prix (`valeur_fonciere`).
- L'adresse et le cadastre : Le nom de la commune, son code postal, et le numéro officiel de la parcelle de terrain (`id_parcelle`). *Attention au piège* : pour les codes postaux commençant par un zéro (comme en Corse), il faut faire attention à ce que l'ordinateur ne supprime pas ce zéro.
- La description du bien : Le type de logement (Maison, Appartement, Local commercial) et la superficie du terrain.
- Les cases vides (valeurs manquantes) :
 - o Les colonnes pour la surface de la maison (`surface_reelle_bati`) et le nombre_pieces sont souvent vides lorsqu'il s'agit de la vente d'un terrain nu ou d'un champ, ce qui est tout à fait normal.
 - o Les coordonnées GPS (latitude et longitude) peuvent parfois être manquantes si le terrain est trop récent ou si les cartes de la commune ne sont pas encore totalement numérisées.

Les zones oubliées et les délais

Il faut garder en tête que ce fichier n'est pas parfait. Il y a deux grands absents : l'Alsace-Moselle et Mayotte, qui n'apparaissent jamais car ils utilisent des systèmes d'enregistrement différents. De plus, à cause des délais administratifs, les ventes des 6 à 12 derniers mois ne sont jamais complètes dans le fichier.

Présentation et Analyse du MCD retenu


Voici le Modèle Conceptuel des Données (MCD) que nous avons choisi de mettre en forme pour restructurer le fichier DVF. Ce schéma traduit graphiquement les dépendances fonctionnelles et les règles de gestion issues de la publicité foncière en France :



- **Normalisation des données géographiques et administratives (Partie gauche)** : Afin de respecter les formes normales et d'éviter les redondances d'informations, l'adresse a été atomisée. Le modèle sépare strictement les entités Departement, Commune et Voie. La Parcelle sert de pivot géographique : elle stocke la géolocalisation spatiale (latitude/longitude) et gère une association optionnelle (cardinalité 0,1) avec la Nature_culture, ce qui permet de classifier l'usage des sols (terrains agricoles, bois, etc.).
- **Modélisation de la transaction (Partie centrale)** : L'entité Mutation matérialise l'acte authentique et centralise les données financières (valeur_fonciere). Les relations Faire_objet et Composer brisent la structure "plate" du fichier source. Ce choix de modélisation est indispensable pour gérer les transactions multi-lignes, puisqu'un acte de vente unique (une mutation) peut englober plusieurs parcelles et être composé de plusieurs Biens distincts.
- **Granularité des biens et gestion de la copropriété (Partie droite)** : Chaque Bien est qualifié par un Type_local (Maison, Appartement, Dépendance). Pour répondre aux spécificités des ventes en copropriété, le modèle intègre une table d'association Lot_Bien reliée à l'entité Lot. Cette approche permet de décomposer précisément les mutations complexes (achat simultané d'un appartement, d'une cave et d'un parking) et d'isoler les surfaces Carrez associées à chaque lot.

Règles de passage au MLD et normalisation

Le Modèle Logique des Données présent traduit la transition du MCD vers une structure relationnelle :



Ce passage applique des règles strictes pour atteindre la 3e Forme Normale (3FN), éliminant ainsi toute redondance.

Respect des Formes Normales (1FN, 2FN, 3FN)

- **1e Forme Normale (1FN)** : Tous les attributs sont atomiques (non divisibles) et chaque table possède sa clé primaire identifiante et soulignée (ex : code_commune, id_mutation).
- **2e Forme Normale (2FN)** : La base est en 1FN et les attributs non-clés dépendent de la totalité de la clé. C'est le cas de la table d'association Lot_Bien, dont les attributs dépendent de la clé composée (id_bien, lot_numero).
- **3e Forme Normale (3FN)** : C'est le cœur de la restructuration du fichier DVF brut d'Etalab. Tous les attributs dépendent uniquement de la clé primaire de leur table. Les dépendances transitives ont été cassées en isolant le Département, la Commune et la Voie. Si le nom d'une rue change, on ne le modifie qu'à un seul endroit (dans Voie), sans impacter les mutations ou les parcelles.

Traduction des associations (Clés étrangères)

L'examen des flèches et des attributs en bleu sur l'image_3de723.png montre la migration des clés selon les cardinalités du MCD :

- Relations 1,1 à 1,N : La clé primaire du côté (1,N) migre comme clé étrangère (en bleu) vers le côté (1,1). Ainsi, code_département migre dans Commune, code_commune migre dans Parcelle et Voie, tandis que id_parcelle est injectée dans Mutation.
- Modélisation de la copropriété : L'entité intermédiaire Lot_Bien hérite des clés primaires de Bien (id_bien) et de Lot (lot_numero). Cette table d'association permet de lier de façon fluide un logement physique aux différents lots théoriques qui composent une même vente.

Les scripts de création des tables grâce au MCD sont disponibles dans notre projet GitHub.

Conception du modèle décisionnel et implémentation dans un SGBD

L'objectif de cette partie est de faire évoluer notre structure relationnelle (conçue pour le stockage et l'intégrité des données) vers une modélisation multidimensionnelle (conçue pour l'analyse de données et la Business Intelligence). Pour ce faire, nous passons d'une base normalisée en 3FN à une architecture décisionnelle.


Identification des faits et dimensions

La transition vers le modèle décisionnel nécessite de séparer les indicateurs quantitatifs mesurables des axes d'analyse qui permettent de filtrer et de regrouper ces indicateurs.

- **Le Fait (Indicateurs d'analyse)** : L'élément central mesurable est la transaction foncière. La table de faits portera sur les montants financiers (valeur_fonciere), le séquençage des actes administratifs (numero_disposition), ainsi que la typologie de l'acte (nature_mutation).
- **Les Dimensions (Axes d'analyse)** : Quatre axes d'analyse ont été isolés pour explorer les données :
 - Le Temps : Permet d'analyser l'évolution des ventes selon une granularité chronologique (année, trimestre, mois, date exacte).
 - La Localisation : Regroupe toute la hiérarchie géographique (du numéro de rue jusqu'au département et à la région) ainsi que l'assise géolocalisée (coordonnées GPS).
 - Le Bien : Consolide l'ensemble des caractéristiques physiques et structurelles du logement ou du local (surfaces, pièces, typologie, et les détails des lots de copropriété).
 - La Nature de Culture : Permet d'analyser l'usage initial et la classification des parcelles de terre (agricoles, bois, etc.).

Conception du schéma en étoile

À partir de l'analyse précédente, nous avons conçu le modèle en étoile :




Ce schéma présente une structure hautement dé-normalisée au niveau de ses branches, ce qui limite le nombre de jointures nécessaires lors de l'exécution de requêtes analytiques lourdes :

- **FAIT_TRANSACTION (Au centre) :** Elle sert de carrefour décisionnel. Elle ne contient pratiquement que des clés étrangères pointant vers les dimensions environnantes, accompagnées de ses métriques de performance (valeur_foncieres).
- **DIM_LOCALISATION et DIM_BIEN (À gauche et à droite) :** Ces dimensions illustrent parfaitement le principe de l'étoile. Les tables relationnelles intermédiaires (comme Voie, Commune, Département d'un côté, ou Lot et Lot_Bien de l'autre) ont été fusionnées et "aplaties". Par exemple, la dimension DIM_BIEN stocke désormais sur une seule et unique ligne les caractéristiques du bien ainsi que la liste de ses 5 premiers lots et leurs surfaces Carrez associées.

Alimentation de l'entrepôt de données avec un ETL

Pour alimenter notre entrepôt de données décisionnel, nous avons conçu et implémenté un pipeline ETL à deux niveaux (*Two-Stage ETL*). Cette architecture technique dissocie la phase d'acquisition et de nettoyage de la phase de restructuration multidimensionnelle, garantissant ainsi l'isolation des processus et une meilleure maintenance du flux.



Choix technologiques et stratégie d'architecture

Pour réaliser ce pipeline, nous avons choisi d'associer deux technologies complémentaires plutôt que d'utiliser un outil ETL graphique classique (comme Talend ou SSIS), afin de maximiser les performances de traitement :

- **Python (bibliothèque Pandas)** : Utilisé pour la phase d'Extraction et de Nettoyage initial (Data Cleaning). Python offre une grande flexibilité pour manipuler les fichiers plats volumineux, appliquer des typages stricts à la volée et s'interconnecter aux bases de données via des pilotes ODBC.
- **Transact-SQL (T-SQL) sous SQL Server** : Utilisé pour les phases de Transformation complexe et de Chargement final (Load). Le traitement direct au sein du SGBD (approche de type ELT) est le plus performant pour exécuter des jointures de masse et distribuer les enregistrements du modèle opérationnel vers le modèle en étoile.

Conception et étapes du flux ETL

Étape 1 : Extraction et sécurisation du typage

Le script Python charge le fichier plat DVF en mémoire dans un DataFrame Pandas. Lors de l'importation, un typage de précaution strict est imposé en forçant les codes géographiques (notamment `code_postal` et `code_commune`) en chaînes de caractères (str). Cette opération est indispensable pour empêcher le moteur d'interprétation de tronquer les zéros initiaux (ex: les communes de Corse ou de l'Ain).

Étape 2 : Nettoyage et normalisation des données (Data Cleaning)

Avant toute insertion, le script Python applique un traitement rigoureux sur les données brutes :

- Valeurs manquantes : Les chaînes vides ou marqueurs d'absence ("NaN", "-") sont convertis en objets None pour garantir l'insertion de marqueurs NULL en SQL.
- Types numériques : Nettoyage et conversion des montants et coordonnées GPS en décimaux (float), et des caractéristiques physiques en entiers (int).
- Dédoublonnage : Utilisation de la méthode `.drop_duplicates()` pour extraire les référentiels uniques (Communes, Voies, Parcelles...) et éliminer les redondances.

Étape 3 : Chargement dans la base relationnelle intermédiaire (OLTP)

Les données segmentées sont insérées par blocs dans la base DVF. Le chargement respecte un ordre séquentiel strict dicté par les clés étrangères (Département, Commune, Parcelle, Mutation, Bien) pour éviter toute violation de l'intégrité référentielle.

Étape 4 : Transformation multidimensionnelle (OLAP)

Une fois la base relationnelle alimentée, un script T-SQL s'exécute sous SQL Server pour structurer l'entrepôt DVF_ETOILE :

- **Dimension Temps** : Génération dynamique de l'année, du trimestre et du mois à partir de la date brute de vente.
- **Aplatissement des axes** : Fusion des tables relationnelles via des jointures. Dans DIM_BIEN, la fonction ROW_NUMBER() OVER permet d'agréger horizontalement jusqu'à 5 lots de copropriété par ligne.
- **Table de faits** : Alimentation de FAIT_TRANSACTION par jointure entre les clés techniques des dimensions et la mesure quantitative valeur_fonciere.

Visualisation des données et création de tableaux de bord

L'objectif de cette phase est de rendre les données foncières lisibles et exploitables par un utilisateur non-technicien, en proposant une lecture multi-dimensionnelle du marché immobilier français. Le tableau de bord Power BI répond à trois grandes questions analytiques : Quelle est l'évolution temporelle du marché ? Quelles sont les disparités géographiques entre départements et communes ? Quel est l'impact des caractéristiques physiques d'un bien (surface, type) sur sa valeur foncière ?

Les données couvertes s'étendent jusqu'au 30 juin 2025 et portent sur l'ensemble du territoire national, soit 7,34 millions de mutations distinctes et 11,68 millions de biens, pour une valeur foncière moyenne de 338 430 € et un prix moyen non pondéré de 6,95 €/m².

Le rapport est structuré en 5 pages thématiques :

- Page "**Accueil**" : Avant d'accéder aux pages analytiques, l'utilisateur est accueilli par une page d'accueil dont le rôle est purement navigationnel et esthétique. Elle présente le titre du rapport ("Analyse des Demandes de Valeurs Foncières"), nos noms, ainsi que les dates de dernière mise à jour des données (30/06/2025) et du rapport (11/06/2026). En bas de page, quatre boutons de navigation permettent d'accéder directement aux pages thématiques : Global, Mutations, Valeur foncière, et Valeur foncière par Surface Bâtie.

ROBART Cyprien
DE BURGGRAEVE Maxime

Analyse des Demandes de Valeur Foncière

Dernières données : 30/06/2025
Dernière MAJ du rapport : 11/06/2026




Global

Mutations



Valeur foncière

Valeur foncière par Surface Bâtie


- Page "Global" : Cette page présente les KPIs clés (nombre de mutations, nombre de biens, valeur foncière moyenne, prix au m²) et un graphique en barres de la distribution mensuelle de la moyenne des prix fonciers. On note un pic important en décembre 2022, avec une moyenne qui approche 0,9 M€. Les deux tableaux classent les départements et communes par moyenne de valeur foncière décroissante : le Jura (39) arrive en tête avec 1 641 507,63 €, suivi de Paris (75) à 1 590 205,97 €. Côté communes, Brandérion affiche la moyenne la plus élevée (215 667 080,87 €) sur seulement 132 mutations, ce qui s'explique probablement par quelques transactions très atypiques. La moyenne nationale s'établit à 338 433,53 €, mais cache de fortes disparités selon les territoires.




- Page "**Mutations**" : Cette page se concentre sur la volumétrie des transactions. Un histogramme mensuel permet de visualiser l'évolution du nombre de mutations dans le temps et d'identifier des saisonnalités. Deux graphiques en barres horizontales mettent en évidence le Top 3 des départements (Nord-59, Bouches-du-Rhône-13, Paris-75) et le Top 3 des communes (Toulouse, Nice, Montpellier) concentrant le plus grand volume d'activité.



- Page "**Valeur foncière**" : Cette page analyse la répartition spatiale et typologique des valeurs. Une carte interactive affiche la moyenne des valeurs foncières par latitude/longitude, permettant d'identifier immédiatement les zones de tension immobilière (Paris et la région PACA). Un diagramme circulaire décompose la répartition des biens par type (Vide, Appartement, Maison, Dépendance, Local industriel), et un graphique en barres illustre les écarts de valeur moyenne selon ce même type : les locaux industriels et commerciaux affichent la valeur moyenne la plus élevée (~1,59 M€), loin devant les appartements (~0,38 M€) et les maisons (~0,32 M€).



- Page "**Valeur foncière par Surface Bâtie**" : Un nuage de points (scatter plot) met en relation la surface réelle bâtie (axe X) et la valeur foncière moyenne (axe Y), coloré par type de bien (hors local industriel). Cette vue permet d'identifier des comportements non-linéaires et des valeurs atypiques : certains biens de grande surface (au-delà de 1 000 m²) atteignent des valeurs supérieures à 100 M€, notamment dans les catégories Vide et Appartement.



Un système de filtres communs à toutes les pages permet à l'utilisateur de filtrer de manière dynamique l'analyse selon : la date (Année, Trimestre, Mois), la localisation (Département, Commune), le type de bien (Type Local), la surface réelle bâtie, le nombre de pièces principales et la nature de culture. L'ensemble de ces filtres garantit une exploration interactive et autonome, sans nécessiter de connaissances techniques particulières.

En regardant les 5 pages du tableau de bord, nous pouvons tirer plusieurs conclusions. Le marché immobilier français est très actif mais pas réparti uniformément : c'est surtout dans quelques départements (Nord, Bouches-du-Rhône, Paris) et grandes villes (Toulouse, Nice, Montpellier) que les transactions sont les plus nombreuses. La moyenne nationale de 338 433,53 € ne veut pas dire grand-chose seule. Selon le département ou le type de bien, les chiffres sont très différents : Paris dépasse 1,59 M€ en moyenne, alors que le Nord reste autour de 390 K€. Les locaux industriels et commerciaux font monter la moyenne globale, tandis que les maisons et appartements se situent plutôt entre 300 et 380 K€.

On remarque aussi une évolution claire dans le temps : l'année 2020 sort du lot avec une baisse visible des transactions, directement liée au COVID-19. Dès 2021, le marché repart à la hausse et retrouve un niveau d'activité normal.

Enfin, plus un bien est grand, plus sa valeur devient difficile à prévoir. Au-delà de 500 m², les prix varient énormément d'un bien à l'autre, car on sort du logement classique pour entrer dans des cas particuliers (entrepôts, hôtels particuliers, etc.).

CONCLUSION

Ce projet nous a permis de parcourir toute la chaîne d'un projet décisionnel, de la donnée brute au tableau de bord, en passant par toutes les étapes qui en garantissent la fiabilité.

La première étape, la rétroconception du fichier DVF, a montré qu'un fichier Open Data en apparence simple peut cacher une vraie complexité technique. La structure dénormalisée, les valeurs manquantes et les transactions multi-lignes ont rendu indispensable une modélisation rigoureuse en 3FN avant toute exploitation analytique. Le passage au schéma en étoile a mis en évidence une tension classique en ingénierie des données : ce qui est bon pour l'intégrité (normalisation, clés étrangères) est l'inverse de ce qui est bon pour la performance analytique. L'aplatissement des dimensions DIM_BIEN et DIM_LOCALISATION est la traduction concrète de ce compromis.

Le pipeline ETL à deux niveaux (Python pour le nettoyage, T-SQL pour la transformation) a montré l'intérêt de choisir le bon outil pour chaque tâche, ce qui a permis de traiter plusieurs millions de lignes sans perte d'intégrité. Enfin, le tableau de bord Power BI valide l'ensemble de cette architecture. Les résultats sont concrets : le marché est géographiquement concentré, les valeurs foncières varient fortement selon le territoire et le type de bien, et l'impact du COVID-19 est clairement visible sur les données 2020. Ces observations n'auraient pas été possibles sans le travail de structuration réalisé en amont.

C'est finalement l'objectif de tout projet décisionnel : transformer une masse de données brutes en informations utiles, accessibles à n'importe quel utilisateur sans compétences techniques particulières.